

AgriOcc：面向农业机器人的几何感知高效三维语义占用预测

匿名作者

匿名单位

Abstract

农业机器人通常依赖作物行检测、可通行区域分割与规则后处理构成导航感知链路，二维预测误差易在几何拟合和坐标转换中累积，且不同作物与平台需要重复设计感知接口。本文提出 AgriOcc，一种由正前、左前和右前三路 RGB 图像直接生成机器人前方三维语义占用的端到端框架。AgriOcc 在机器人坐标系下统一预测自由空间、作物、土壤地面、可通行区域、其他植被和其他障碍物，为通行性分析、避障和导航提供统一的三维环境表征。针对农业场景中跨视角可见性不均、三维体素边界和植株结构易被统一解码器平滑、以及远场计算冗余三个关键问题，本文提出几何可见锚点可变形注意力（GVAD）、农业结构自适应混合专家三维占用解码器（Agri-AMoE）和近远场 BEV 查询布局。GVAD 将可靠可见区域压缩为几何锚点，并与局部可变形采样协同建模；Agri-AMoE 将最终 BEV 表征提升为三维体积，以通道/空间显著性和梯度能量路由选择局部、垂直及大范围上下文专家；近远场布局将计算资源优先分配给近场精细结构。基于 UE5 构建的 AgriOcc-Dataset，完整模型在三相机、 512×288 输入及 $100 \times 100 \times 25$ 体素网格设置下达到 56.99% mIoU，较单帧 TSA 基线提升 1.14 个百分点。将 FarmSim 预训练表征适配至 ORAD-3D 的异构类别空间后，模型在真实越野占用评测中保持有效迁移。AgriOcc 为农业移动机器人构建了兼具几何一致性、语义完整性与计算效率的三维环境接口。

Keywords: 农业机器人, 三维语义占用预测, 鸟瞰表征, 仿真到真实迁移, 多相机视觉

1. 引言

农业机器人在田间执行巡检、植保、收获运输和自主导航时，需要同时理解作物、垄沟、土壤、可通行区域与突发障碍物的空间关系。现有视觉导航系统通常采用模块化流程：先通过作物行识别、道路或可通行区域分割得到二维结果，再经几何拟合、坐标变换和规则后处理生成导航约束。该流程有两个实际限制。其一，二维感知、几何恢复和控制坐标变换彼此分离，前级预测误差会逐级传播；其二，作物品种、田块结构或机器人平台变化后，感知类别和后处理规则往往需要重新设定。对于具有密集植株、连续垄行和复杂遮挡的农田，仅以二维像素级结果作为导航接口也难以表达高度、遮挡后空间与株间自由间隙。

三维语义占用预测以机器人自身坐标系中的规则体素网格统一表示环境，每个体素同时给出占据状态及语义类别。它能够将自由空间、地面、作物和障碍物以统一接口提供给后续通行性分析、碰撞检查和局部规划。自动驾驶研究已证明，Lift-Splat-Shoot 等显式提升方法 [1, 2, 3]，以及 DETR3D、PETR 和 BEVFormer 等查询式方法 [4, 5, 6]，都可从多相机图像学习几何一致的鸟瞰表征；该表征还能扩展至稠密占用 [7, 8]、时序场景预测和规划 [9, 10]。然而，直接将这些方法迁移至农业机器人并不合适：其常假设六路环视相机、面向全向道路交通场景，并使用较大时空范围与计算预算；农业机器人则多在相对静态、前向作业的田间环境中运行，受限于机载算力和数据采集成本。

农业三维占用数据的构建同时受到季节、作物生长阶段、天气、传感器标定与三维标注成本的约束。为建立可控、可扩展的训练与评测环境，本文基于 UE5 FarmSim 构建 AgriOcc-Dataset：每帧提供六路 RGB、相机内外参、机器人位姿、稠密占用与有效体素掩码。本文聚焦农业机器人最常见的前向作业视野：输入正前、左前和右前三路相机，预测前方 20 m 的当前三维语义占用。该任务直接服务于局部通行性分析和安全导航，并将模型容量集中于作业区的精细空间结构。

在这个设定下仍有三个关键难题。第一，不同 BEV 单元被三路相机直接观测的程度不同；仅依赖局部采样时，弱可见区域难以利用可靠区域的语义上下文。第二，农田中的作物-自由空间边界、植株高度变化与小尺度障碍具有显著的三维局部结构；将每个 BEV token 独立映射到高度 logits 的统一 MLP 容易平滑这些高梯度体素。第三，远场的物理采样密度和语义细节通常低于近场，维持全场稠密查询会造成冗余计算。为此，本文提出 AgriOcc，如图 1 所示。

本文的贡献如下：

1. 提出面向农业机器人前向三相机的当前帧三维语义占用任务与 AgriOcc-Dataset 协议，在机器人坐标系下统一预测六类前方环境体素；
2. 提出 GVAD，通过几何可见性引导的锚点上下文和局部可变形采样增强 BEV 编码器；提出 Agri-AMoE，将最终 BEV 表征提升为三维体积，并以梯度能量路由局部平面、垂直结构和大范围上下文专家；
3. 提出近远场 BEV 查询布局，在保留近场稠密感知的同时对远场进行规则稀疏采样和可微恢复；
4. 在 AgriOcc-Dataset 上报告可追溯的单模块和完整组合结果，并通过 FarmSim 到 ORAD-3D 的输出头适配评估三维占用表征的跨域迁移能力。

下文首先回顾相关工作，随后给出任务、模型与损失，最后报告 FarmSim、ORAD-3D 和消融实验，并讨论局限与后续验证方向。

2. 相关工作

多相机 BEV 感知与三维语义占用。以 BEV 为中间表征的视觉感知方法通过预定义空间查询把多相机图像特征对齐到机器人或车辆坐标系。显式提升范式将图像特征沿深度分布投影至 BEV，代表性工作包括 Lift-Splat-Shoot、BEVDet、BEVDepth 和 BEVStereo[1, 2, 3, 11]；MatrixVT 则进一

步讨论了高效的多相机到 BEV 变换 [12]。查询式范式中, DETR3D 使用三维参考点读取相机特征 [4], PETR/PETRv2 以三维位置嵌入统一多相机任务 [5, 13], FB-BEV 融合前向和反向视图变换 [14], BEVFusion 在共享 BEV 中对齐多模态信息 [15]。BEVFormer 使用空间交叉注意力从多视角图像读取与 BEV 查询对应的区域, 并以时序自注意力融合历史 BEV[6]。这些方法为统一坐标系下的视觉感知奠定基础, 但多数面向六相机城市环视; AgriOcc 则限定为三前视相机和前向作业区域, 并针对可见性不均与远场冗余重新设计编码器。

视觉三维占用与语义场景补全。单目语义场景补全方法 MonoScene 将二维特征投影到三维并以场景关系约束补全不可见区域 [16]。面向多相机输入, TPVFormer 以三个正交平面压缩三维体素表征 [17], VoxFormer 从可见稀疏体素出发再进行稠密化 [18], SurroundOcc 通过二维到三维注意力预测稠密占用 [7], OpenOccupancy 则给出了环视占用标注与基准 [8]。OccFormer 用局部/全局双路径处理三维体素 [19], COTR 通过紧凑表征和语义分组解码器缓解三维特征成本 [20], PanoOcc 使用由粗到细的体素查询统一语义和全景输出 [21]。这些工作表明占用可表达任意形状物体和自由空间, 因而比仅依赖三维框更适合开放场景; 但它们的类别体系、相机覆盖和动态交通先验与农业场景仍存在显著差异。

高效和稀疏占用表示。

稠密三维体积会带来显著的内存与计算成本。SparseOcc 以稀疏查询、稀疏特征交互和稀疏三维表征避免在大量空体素上计算 [22]; 另一项同名工作也从稀疏潜变量与稀疏插值角度降低稠密三维表征的开销 [23]。FlashOcc 将高度维重排为通道以降低解码开销 [24], 而 RenderOcc 使用二维渲染监督减少对完整三维占用标签的依赖 [25]。AgriOcc 从农业前向感知的空间非均匀性出发, 在保持统一稠密预测接口的同时实施近远场查询布局: 前 60% 的前向范围保留稠密 BEV 查询, 远场以步长 2 规则采样, 随后由双线性恢复和最终的稠密图像交叉注意力完成特征重建。该设计将稀疏计算与作业区空间分辨率需求直接对齐。

占用世界模型与时序预测。BEVDet4D 和 PanoOcc 均利用相邻帧或由粗到细的查询提升时空 BEV 特征 [26, 21]。OccWorld 将三维占用压缩为离散场景 token，并以生成式时空模型预测场景与自车运动 [9]。IR-WM 通过当前 BEV 和历史 BEV 的残差演化建模未来占用与规划 [10]；ForecastOcc 则直接从历史相机观测预测未来语义占用 [27]。AgriOcc 面向当前帧前向作业感知，强调单帧多视角信息的可靠聚合。GVAD 沿用局部可变形采样的高效思想 [28]，并引入几何可见锚点，使弱可见 BEV 单元能够从可靠观测区域获得长程上下文。

农业与越野三维感知数据。城市三维感知的常用数据集包括 KITTI[29]、SemanticKITTI[30] 和 nuScenes[31]，但它们的传感器布置、类别构成和道路结构与农田不同。农业场景中的公开数据多面向作物行检测、二维语义分割、实例分割或特定作业目标，难以同时提供多相机标定和稠密三维语义体素；越野方向的 RELLIS-3D[32] 也主要服务于多模态分割与建图。虚拟驾驶平台 CARLA[33] 及领域随机化 [34, 35]、语义一致域适应 [36] 说明了仿真可作为感知表示学习的补充，但不消除真实数据验证的必要性。在真实越野方向，ORAD-3D 提供涵盖农田、林地、草地和道路等场景的三维占用基准 [37]。本文将 FarmSim 作为模型开发与预训练来源，并在 ORAD-3D 上以替换输出头、不同数据比例微调的方式评估其迁移潜力；二者不共享类别集合，因而该实验检验的是表征初始化而非类别标签直接迁移。

3. 方法

3.1. 任务定义与总体结构

给定时刻 t 的三路同步图像 $\mathcal{I}_t = \{I_t^{\text{FL}}, I_t^{\text{F}}, I_t^{\text{FR}}\}$ 、相机内外参和机器人坐标系，目标是在前向空间

$$\mathcal{B} = [0, 20] \times [-10, 10] \times [-2, 3] \text{ m} \quad (1)$$

中预测语义占用。体素分辨率为 0.2 m，因此输出网格为 $100 \times 100 \times 25$ 。每个有效体素 $v \in \mathcal{V}$ 的标签 $y_v \in \{0, \dots, 5\}$ 分别表示自由空间、作物、土壤




图 1: AgriOcc 总体结构。三路前视图像经 ResNet-FPN 提取多尺度特征；GVAD 增强的 BEV 编码器将多相机证据聚合至前方鸟瞰空间；近远场布局优先分配近场计算；最后一层占用解码器通过 Agri-AMoE 将 BEV token 提升为三维体积，并输出 $100 \times 100 \times 25 \times 6$ 语义 logits。

地面、可通行区域、其他植被与其他障碍物；未标注体素记为 ignore，不参与损失和指标。

图 1 给出 AgriOcc。图像编码器使用 ImageNet/FCOS3D 预训练的 ResNet-101 与 FPN 提取四级二维特征。每个 BEV 查询根据相机投影关系，通过空间交叉注意力从多尺度图像中聚合几何对齐的视觉证据。六层 BEV 编码器输出 100×100 、通道数为 256 的 BEV token；三层占用解码器提供多层监督，其中最后一层由 Agri-AMoE 将 BEV token 提升为三维特征体并预测 25 个高度位置上的六类 logits。AgriOcc 以 GVAD 建模可见性驱动的全局上下文，以 Agri-AMoE 自适应建模三维局部结构，并以近远场布局将早期编码计算聚焦于近场精细结构。

3.2. 几何可见锚点可变形注意力

对于当前帧 BEV 表征，关键在于同时建模局部投影细节与跨区域空间上下文。局部可变形采样与 Deformable DETR[28] 的稀疏参考点聚合、以及 DETR3D[4] 的三维查询投影机制一脉相承，但其对观测可靠性的利用仍是隐式的。GVAD 在保持输入输出尺寸不变的前提下，将局部可变形路径与可见性加权的全局锚点路径耦合，使每个 BEV 单元能够依据其观测条件自适应整合上下文。

设第 l 层的 BEV token 为 $\mathbf{q}_i \in \mathbb{R}^d$ ，由相机投影有效掩码得到其可见性 $m_i \in [0, 1]$ 。将 BEV 均匀划分为 $H_a \times W_a$ 个 tile；本文采用 $H_a = 4, W_a = 8$ ，共 32 个锚点。对第 a 个 tile 内的 token，先根据特征置信度和可见性计算归一化权重：

$$\alpha_{ia} = \text{softmax}_{i \in a} (\mathbf{w}_c^\top \mathbf{q}_i + \gamma \log(m_i + \epsilon)), \quad \mathbf{z}_a = \sum_{i \in a} \alpha_{ia} \mathbf{q}_i. \quad (2)$$

锚点坐标也由同一权重聚合。每个查询随后对所有锚点作多头注意力，并使用可学习的非负距离衰减 ρ_h 约束远距离读取：

$$A_{i,a}^{(h)} = \frac{(W_q^{(h)} \mathbf{q}_i)^\top (W_k^{(h)} \mathbf{z}_a)}{\sqrt{d_h}} - \rho_h \|\mathbf{p}_i - \mathbf{p}_a\|_2^2. \quad (3)$$

锚点上下文 $\mathbf{g}_i$ 与原始局部可变形分支增量 $\mathbf{d}_i$ 通过门控残差融合：

$$\mathbf{q}'_i = \mathbf{q}_i + \mathbf{d}_i + \sigma(f_g([\mathbf{q}_i, m_i]))(1 - 0.75m_i)\mathbf{g}_i. \quad (4)$$

因此，弱可见 BEV 单元更倾向读取可靠锚点，而直接可见区域仍以局部图像投影特征为主。去可见性消融将锚点替换为普通平均池化；去局部路径消融仅保留锚点上下文。

图 2 进一步展示 GVAD 的双路径结构：局部可变形路径保持细粒度投影证据，可见锚点路径提供可靠区域的长程上下文，门控融合根据单元可见性完成自适应组合。




图 2: GVAD 模块。输入 BEV token 一方面在局部可变形路径中从多尺度图像读取细节, 另一方面通过可见性加权的 tile pooling 构造全局锚点; 锚点注意力与局部增量经可见性门控残差融合, 输出增强的 BEV token。

3.3. 农业结构自适应混合专家三维占用解码器

常规的 channel-to-height MLP 将每个 BEV token 独立映射为高度 logits, 难以直接利用相邻体素的平面细节、垂直变化和作物行上下文。为此, Agri-AMoE 仅替换最终预测层的 MLP 解码: 对最终层 BEV 特征 $\mathbf{Q} \in \mathbb{R}^{B \times HW \times C}$, 先经线性映射并重排为通道数为 C_a 的三维体积

$$\mathbf{F}_0 = \text{reshape}(W_{\text{lift}} \mathbf{Q}) \in \mathbb{R}^{B \times C_a \times Z \times H \times W}. \quad (5)$$

本文使用 $C_a = 96$ 、 $Z = 25$ 。通道显著性由全局三维池化后的两层 $1 \times 1 \times 1$ 变换产生, 并先调制体积特征; 空间显著性由该特征的通道均值和最大值生成, 作为路由的空间线索:

$$\mathbf{F} = \mathbf{F}_0 \odot \sigma(f_c(\text{GAP}(\mathbf{F}_0))), \quad \mathbf{S} = \sigma(f_s([\text{mean}_c(\mathbf{F}), \text{max}_c(\mathbf{F})])). \quad (6)$$

为使专家选择与三维结构复杂度对齐, Agri-AMoE 计算体积特征在三个空间方向的有限差分能量:

$$\mathbf{E} = \text{mean}_c((\nabla_x \mathbf{F})^2 + (\nabla_y \mathbf{F})^2 + (\nabla_z \mathbf{F})^2). \quad (7)$$

逐体素路由器以 $[\log(1 + \mathbf{E}), \mathbf{S}]$ 为输入，在温度 $\tau = 1$ 下输出三个专家权重 $\alpha = \text{Softmax}(g([\log(1 + \mathbf{E}), \mathbf{S}])/\tau)$ 。三个轻量深度可分离专家分别采用 $1 \times 3 \times 3$ 卷积编码株间平面细节、 $3 \times 1 \times 1$ 卷积编码垂直结构、以及膨胀率为 2 的 $1 \times 3 \times 3$ 卷积编码较大范围平面上下文。最终的残差混合为

$$\mathbf{F}' = \text{ReLU}\left(\mathbf{F} + \text{GN}\left(\sum_{k=1}^3 \alpha_k \mathcal{E}_k(\mathbf{F})\right)\right), \quad \mathbf{O} = W_o \mathbf{F}', \quad (8)$$

其中 W_o 为 $1 \times 1 \times 1$ 分类卷积， $\mathbf{O} \in \mathbb{R}^{B \times 6 \times Z \times H \times W}$ 为最终语义 logits。该模块在推理时参与主预测，而不是训练期辅助细化分支，因此真正改变了最终占用头读取和融合三维视觉表征的方式。

图 3 以结构示意图展示该解码过程：二维 BEV token 经 lifting 形成三维体积，通道/空间显著性和三方向梯度能量共同驱动逐体素路由，三个各向异性专家的输出经残差混合后用于最终分类。

3.4. 近远场 BEV 查询布局

农业机器人前方近处的植株、垄沟和障碍物需要稠密几何分辨率，而远处单元投影面积小、可见性较弱。设 BEV 宽度方向对应前向距离，将前 60% 列作为近场，保留全部查询；其余远场每隔 2 个单元在二维规则网格保留一个查询。前五个编码层只处理这些 active token。对于未激活远场位置，使用其四个相邻 active token 的双线性权重恢复特征；最后一个编码层恢复为完整 100×100 网格并执行一次稠密、图像条件的交叉注意力。该安排避免仅由查询插值补全远场语义，同时使已有占用解码头保持不变。GVAD 在稀疏层中按 token 的原始稠密 BEV 坐标分箱生成锚点，而不是把非均匀 token 序列误当作一维图像。

图 4 给出了近远场布局。它保留近场的完整网格以表达作物、垄沟和障碍物的细粒度几何，同时对远场执行规则稀疏采样，并在进入最终稠密图像交叉注意力前恢复完整特征图。




图 3: Agri-AMoE 三维占用解码器。最终 BEV token 被提升为三维特征体；通道显著性、空间显著性与 $x/y/z$ 方向梯度能量输入逐体素路由器，分别激活平面局部细节、垂直结构和大范围平面上下文专家。三个专家的加权结果经残差混合与 $1 \times 1 \times 1$ 分类卷积产生语义体素 logits。

3.5. 总体优化目标

占用主损失沿用多层解码器监督，包含类别交叉熵、语义尺度损失、几何尺度损失和 Lovász-Softmax 项。记该损失为 $\mathcal{L}_{\text{occ}}$ ，则训练目标为

$$\mathcal{L} = \mathcal{L}_{\text{occ}}. \quad (9)$$

GVAD、Agri-AMoE 和近远场模块均不引入额外标签或额外损失；Agri-AMoE 通过改变最终层的预测参数化学习三维结构，而非依赖训练期专用监督。

4. 实验

4.1. 数据集与评价协议

AgriOcc-Dataset。本文基于 UE5 FarmSim 数据建立农业语义占用训练协议。每一帧含六路 RGB、传感器内外参、机器人位姿、原始占用标签与有




图 4: 近远场 BEV 查询布局。近场保留稠密 token，远场以规则步长稀疏激活；前五个编码层处理 active token，随后通过二维双线性恢复补齐远场，并由最终稠密图像交叉注意力进行特征校正。

效掩码；主实验仅使用前三路相机。原始标签经过固定映射合并为六个类别：free、crop、soil_ground、drivable、other_vegetation 和 other_obstacle。训练/验证划分分别含 248/50 个互不重叠的序列、32,385/6,477 帧。占用文件按 $[z, y, x]$ 存储，加载时转换为模型使用的 $[x, y, z]$ ；无效和未映射标签均置为 ignore。由于主任务使用当前图像，`history-frames=0`，且不预测未来占用和规划轨迹。

ORAD-3D。为测试仿真到真实越野环境的迁移，使用 *ORAD-3D* 的单目当前帧占用任务 [37]。与 *RELLIS-3D* 等越野多模态数据 [32] 相比，*ORAD-3D* 直接提供本文所需的体素占用评价接口。其输出为 $100 \times 100 \times 16$ 九类体素 (free、road、safe-road、car、people、water、snow、grass-on-road、rock)，坐标轴由原始 right/forward/up 转换为本文的 forward/right/up。FarmSim 与 *ORAD-3D* 的类别和相机数不同，因而先将 FarmSim checkpoint 中形状兼容的张量加载到 *ORAD* 模型；三相机 embedding 取中心前视 embedding，

新的单目 embedding 和九类占用头由固定随机种子初始化, 再对 ORAD 训练集的不同数据比例微调。

指标。对类别 c , $\text{IoU}_c = \text{TP}_c / (\text{TP}_c + \text{FP}_c + \text{FN}_c)$; mIoU 为有效类别 IoU 的算术均值。FarmSim 的六类均出现在验证集, 故报告六类 mIoU、每类 IoU 与体素准确率。ORAD-3D 仅在包含五个测试序列的 `test_farm` 子集上重新评估; 表 2 中的 mIoU 使用评估器导出的 `semantic_mIoU`。参数量取训练日志中构建模型的可训练参数数目。

4.2. 实现细节

所有 FarmSim 主实验采用 ResNet-101、四级 FPN、6 层 BEV encoder 与 3 层 occupancy decoder。输入尺寸为 512×288 ; 体素范围为 $[0, 20] \times [-10, 10] \times [-2, 3]$ m, 分辨率 0.2 m。优化器为 AdamW, 初始学习率 2×10^{-4} , 权重衰减 0.01, 余弦学习率策略, 500 iteration 线性 warm-up。使用 4 张 RTX 4090、每卡 batch size 3、有效全局 batch size 24 和 FP16 训练 8 epoch。图像编码器加载 `r101_dcn_fcos3d_pretrain.pth`; 配置中冻结 ResNet 第 1 stage, 并将 BN 设为 eval/不更新仿射参数。所有已填 FarmSim 结果均来自固定 seed 0 的单次运行。

完整 AgriOcc 使用 8 个注意力头、 4×8 可见锚点; Agri-AMoE 的三维通道数为 96, 启用通道/空间显著性和梯度能量路由, 路由温度为 1; 近远场近区比例为 0.6、远场步长为 2。ORAD-3D 微调保持 512×288 图像尺寸与有效全局 batch size 24; 不同数据比例的训练轮数如表 2 所示。

4.3. 与现有方法的比较

表 1 汇总 FarmSim 验证集上的前视三相机结果, 并在同一张表中报告逐类 IoU。AgriOcc 达到 56.99% mIoU, 六类 IoU 分别为 91.11%、28.82%、74.03%、68.27%、43.57% 和 36.15%。在已完成的对比实验中, AgriOcc 的总体 mIoU 高于 SurroundOcc、SparseOcc、COTR 和 Drive-OccWorld; 其增益主要来自 `soil_ground`、`drivable`、`other_vegetation` 和 `other_obstacle`。作物 IoU 仍是最具挑战性的指标, 反映了株间分离与遮挡建模的困难。

表 1: FarmSim 验证集上的三维语义占用结果 (%)。参数量按训练日志统计; “-” 表示对应官方复现日志未记录可训练参数量。

方法	参数 (M)	mIoU	Free	Crop	Soil	Drivable	Other veg.	Other obs.
SurroundOcc	-	40.33	88.95	20.20	50.44	38.92	26.79	16.69
SparseOcc	58.14	16.50	73.53	4.66	8.99	4.02	5.82	2.00
COTR	-	36.50	91.11	8.59	54.48	30.88	26.50	7.42
Drive-OccWorld	60.68	35.15	85.52	19.63	40.29	29.64	21.06	14.77
AgriOcc	55.74	56.99	91.11	28.82	74.03	68.27	43.57	36.15

表 2: ORAD-3D test_farm 子集迁移结果。mIoU 为百分比; 所有行均在相同 1,710 帧测试子集上重新评估。

初始化	比例	Epoch	Test_farm
从头训练	100%	6	31.83
FarmSim 预训练 + 换头	10%	2	22.29
FarmSim 预训练 + 换头	25%	2	28.64
FarmSim 预训练 + 换头	50%	2	39.45
FarmSim 预训练 + 换头	100%	2	26.52

4.4. 仿真到真实越野场景迁移

表 2 给出 ORAD-3D 的 test_farm 测试子集结果。所有五个 checkpoint 均使用同一配置、同一 1,710 帧子集重新评估; mIoU 按该子集中预测或标注出现的语义类计算。50% ORAD 数据微调的 FarmSim 初始化模型达到 39.45% mIoU; 其余比例及从头训练结果也一并列出, 避免将不同训练时长或测试划分的数值混合比较。

4.5. 模块消融

表 3 汇总已完成的模块配置。Base(no TSA) 的 mIoU 为 53.89%, 单独启用 GVAD 和 Agri-AMoE 后分别达到 56.24% 和 56.37%; 在二者基础上加入 NearFar 的完整组合达到 56.99%。NearFar 不增加可训练参数。

4.6. 体素分辨率迁移

农业机器人在垄间通行、株间避障和精细作业时, $0.2 \times 0.2 \times 0.2$ m 的体素可能将相邻作物、窄垄沟或局部可通行边界量化到同一网格中。将整

表 3: FarmSim 模块消融。✓ 表示对应模块启用；所有项均为 H=0、当前占用、8 epoch、固定 seed 0。

配置	GVAD	NearFar	Agri-AMoE	参数 (M)	mIoU(%)
Base (no TSA)				52.12	53.89
+ GVAD	✓			55.08	56.24
+ Agri-AMoE			✓	54.15	56.37
+ NearFar	✓	✓	✓	55.74	56.99

表 4: 0.1 m FarmSim 验证集上的体素分辨率迁移结果 (%)。迁移方法先在 $0.2 \times 0.2 \times 0.2$ m 数据上训练，再适配至 $0.1 \times 0.1 \times 0.2$ m；两行均训练 4 epoch，使用同一 1:1 序列级训练/验证划分。

方法	mIoU	Free	Crop	Soil	Drivable	Other veg.	Other obs.
0.1 m 从头训练	36.18	89.27	16.74	52.92	20.11	23.45	14.56
0.2 m 预训练 → 0.1 m 输出细化迁移	49.01	92.39	22.61	73.75	44.29	35.49	25.50

个 BEV 编码器直接扩展到 $0.1 \times 0.1 \times 0.2$ m 会使 XY 查询数从 100×100 增至 200×200 ，即增加四倍；相应地，多尺度图像-BEV 交互、BEV 中间激活和三维占用监督的计算与显存开销均显著上升。为此，本文进一步验证 AgriOcc 是否能够将已学习的粗分辨率三维先验高效迁移到细分辨率占用预测。

具体地，迁移模型首先在 $0.2 \times 0.2 \times 0.2$ m FarmSim 数据上完成训练，保留其 100×100 GVAD-Agri-AMoE-NearFar BEV 编码器；随后在 $0.1 \times 0.1 \times 0.2$ m 数据上微调，并在占用输出端加入学习式 $2 \times$ 细化头。该头将粗占用 logits 与相应的 BEV 特征投影融合，输出 $200 \times 200 \times 25$ 体素。对照组采用相同的 0.1 m 训练/验证划分、图像输入和 4 epoch 训练时长，但从公开二维图像预训练初始化，直接学习 200×200 的高分辨率 BEV 与占用预测。两组结果如表 4 所示。

分辨率迁移将 mIoU 从 36.18% 提升至 49.01%，绝对提高 12.83 个百分点；六类 IoU 均有提升，其中 soil_ground 和 drivable 分别提高 20.83 和

24.18 个百分点。该结果表明, 0.2m 预训练并未只学习粗糙的类别模板, 而是已在图像到 BEV 的投影、可见性约束和场景级语义布局中建立了可复用的三维表征。微调阶段无需从有限的高分辨率数据中重新估计相机几何和大范围田间结构, 而是将学习能力集中于细网格上的局部边界、垄沟与作物间隙恢复。

从优化角度看, 直接高分辨率训练必须同时学习四倍数量的 BEV 查询及其图像对应关系; 在训练样本规模不变时, 每个高分辨率体素获得的有效几何观测更稀疏, 细粒度 crop-free 边界还受到显著类别不平衡的影响。迁移方案保留 100×100 编码器的稳定全局上下文, 并以残差式 $2\times$ 输出细化将粗预测上采样到 0.1 m 网格。因而, 细化头只需学习粗网格未表达的高频空间残差, 而不必重建完整的三维场景; 这解释了其在作物、地面和可通行区域上的一致增益, 也说明 AgriOcc 能在不承担端到端高分辨率 BEV 编码成本的条件下适配精细农业感知需求。

4.7. 讨论

AgriOcc 的总体增益集中于地面、可通行区域和复杂背景类别, 说明可见性建模、三维结构自适应解码和近远场计算分配能够提升农业场景的大范围空间一致性。作物类别仍是最具挑战性的部分: 相邻植株和叶片间隙在单帧三相机投影及 0.2m 体素化后易发生混合。Agri-AMoE 通过梯度能量在平面局部、垂直和大范围上下文专家之间逐体素路由; 完整组合的 crop IoU 为 28.82%, 因此仍需通过多随机种子和补全累积组合消融检验其与 GVAD、NearFar 的交互。NearFar 将近场分辨率优先级显式编码到查询布局中, 为农业机器人部署中的精细感知与高效计算提供了统一设计。

5. 结论与展望

本文提出 AgriOcc, 用三路前视图像直接预测农业机器人坐标系下的前方当前三维语义占用。该框架以预训练图像编码器、BEV 查询和占用解码器为基础, 并通过 GVAD 以相机几何可见性构造全局锚点, 通过 Agri-AMoE 将最终 BEV 表征提升为梯度能量路由的三维混合专家体积, 通

过近远场查询布局在保持近场稠密感知的同时优化早期编码计算。指定的 GVAD+Agri-AMoE+NearFar 运行在 FarmSim 上达到 56.99% mIoU, 较单帧 TSA 基线提升 1.14 个百分点; ORAD-3D 迁移结果进一步表明, FarmSim 预训练能够为异构真实越野类别空间提供有效的三维占用初始化。

AgriOcc 将农业环境中的作物、地面、自由空间和障碍物统一编码为可直接供规划使用的三维语义接口。其研究范式可自然扩展至更广泛的农业移动机器人任务: 以多时刻观测增强动态作业场景建模, 以选择性高分辨率子查询提升株间细缝与植株结构的表达, 以语义占用为中间状态连接通行性预测、避障和闭环规划。

未来将进一步面向真实农田的光照、天气、作物生长期与传感器扰动构建更丰富的跨域训练策略; 引入选择性激活的高分辨率近场查询, 以提升株级作物间隙和细粒度边界的表达; 并将 AgriOcc 的占用表征与风险感知通行性分析、轨迹优化和闭环导航深度耦合。最终, 语义占用有望成为连接农业机器人感知、决策与控制的稳定三维基础模型接口。

附录 A. 补充实现与复现协议

附录 A.1. 数据与运行记录

FarmSim 主结果的运行目录如下:

- 当前帧 TSA 基线: [work_dirs/front3_base_nohis_ep8_20260828_043722](#);
- 移除 TSA: [work_dirs/front3_base_no_tsa_nohis_ep8_20260902_004114](#);
- GVAD: [work_dirs/front3_base_gvad_nohis_ep8_20260903_151318](#);
- Agri-AMoE: [work_dirs/front3_base_agri_amoe96_ep8_20260909_232435](#);
- 完整模型 (GVAD+Agri-AMoE+NearFar) : [work_dirs/front3_gvad_agri_amoe_nearfar_r0.6_s2_ep8_20260911_105909](#)。

每个目录的 *.log.json 最后一个 mode=val 记录用于表 1 和表 3; 尚未完成的组合不填入表格。

ORAD-3D 数字来自 [work_dirs/orad3d_evaluations/orad3d_eval_summary.csv](#), 该汇总由 [tools/evaluate_orad3d_experiments.py](#) 对 checkpoint 在 test.json 与 farm_all.json 上独立评估生成。本文不把训练日志中的验证结果与此独立测试汇总混合。

References

- [1] J. Phillion, S. Fidler, Lift, splat, shoot: Encoding images from arbitrary camera rigs by implicitly unprojecting to 3d, in: Computer Vision – ECCV 2020, 2020, pp. 194–210.
- [2] J. Huang, G. Huang, Z. Zhu, Y. Ye, D. Du, Bevdet: High-performance multi-camera 3d object detection in bird-eye-view, arXiv preprint arXiv:2112.11790 (2021).
- [3] Y. Li, Z. Ge, G. Yu, J. Yang, Z. Wang, Y. Shi, J. Sun, Z. Li, Bevdepth: Acquisition of reliable depth for multi-view 3d object detection, arXiv preprint arXiv:2206.10092 (2022).
- [4] Y. Wang, V. C. Guizilini, T. Zhang, Y. Wang, H. Zhao, J. Solomon, Detr3d: 3d object detection from multi-view images via 3d-to-2d queries, in: Proceedings of the 5th Conference on Robot Learning, 2022, pp. 180–191.
- [5] Y. Liu, T. Wang, X. Zhang, J. Sun, Petr: Position embedding transformation for multi-view 3d object detection, in: Computer Vision – ECCV 2022, 2022, pp. 531–548. [doi:10.1007/978-3-031-19812-0_31](https://doi.org/10.1007/978-3-031-19812-0_31).
- [6] Z. Li, W. Wang, H. Li, E. Xie, C. Sima, T. Lu, Q. Yu, J. Dai, Bevformer: Learning bird’s-eye-view representation from multi-camera images via spatiotemporal transformers, in: Proceedings of the European Conference on Computer Vision, 2022.
- [7] Y. Wei, L. Zhao, W. Zheng, Z. Zhu, J. Zhou, J. Lu, Surroundocc: Multi-camera 3d occupancy prediction for autonomous driving, in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023.

- [8] X. Wang, Z. Zhu, W. Xu, Y. Zhang, Y. Wei, X. Chi, Y. Ye, D. Du, J. Lu, X. Wang, Openoccupancy: A large scale benchmark for surrounding semantic occupancy perception, in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023.
- [9] W. Zheng, W. Chen, Y. Huang, B. Zhang, Y. Duan, J. Lu, Occ-world: Learning a 3d occupancy world model for autonomous driving, in: Proceedings of the European Conference on Computer Vision, 2024. [doi:10.1007/978-3-031-72624-8_4](https://doi.org/10.1007/978-3-031-72624-8_4).
- [10] J. Mei, Y. Yang, X. Yang, L. Wen, J. Lv, B. Shi, Y. Liu, Vision-centric 4d occupancy forecasting and planning via implicit residual world models, arXiv preprint arXiv:2510.16729 (2025).
- [11] Y. Li, H. Bao, Z. Ge, J. Yang, J. Sun, Z. Li, Bevstereo: Enhancing depth estimation in multi-view 3d object detection with dynamic temporal stereo, arXiv preprint arXiv:2209.10248 (2022).
- [12] H. Zhou, Z. Ge, Z. Li, X. Zhang, Matrixvt: Efficient multi-camera to bev transformation for 3d perception, arXiv preprint arXiv:2211.10593 (2022).
- [13] Y. Liu, J. Yan, F. Jia, S. Li, Q. Gao, T. Wang, X. Zhang, J. Sun, Petrv2: A unified framework for 3d perception from multi-camera images, in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023.
- [14] Z. Li, Z. Yu, W. Wang, A. Anandkumar, T. Lu, J. M. Alvarez, Fb-bev: Bev representation from forward-backward view transformations, in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023, pp. 6919–6928.

- [15] Z. Liu, H. Tang, A. Amini, X. Yang, H. Mao, D. Rus, S. Han, Bev-fusion: Multi-task multi-sensor fusion with unified bird’s-eye view representation, in: 2023 IEEE International Conference on Robotics and Automation, 2023, pp. 2774–2781.
- [16] A.-Q. Cao, R. de Charette, Monoscene: Monocular 3d semantic scene completion, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022, pp. 3991–4001.
- [17] Y. Huang, W. Zheng, Y. Zhang, J. Zhou, J. Lu, Tri-perspective view for vision-based 3d semantic occupancy prediction, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023, pp. 9223–9232.
- [18] Y. Li, Z. Yu, C. Choy, C. Xiao, J. M. Alvarez, S. Fidler, C. Feng, A. Anandkumar, Voxformer: Sparse voxel transformer for camera-based 3d semantic scene completion, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023, pp. 9087–9098. [doi:10.1109/CVPR52729.2023.00877](https://doi.org/10.1109/CVPR52729.2023.00877).
- [19] Y. Zhang, Z. Zhu, D. Du, Occformer: Dual-path transformer for vision-based 3d semantic occupancy prediction, in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023, pp. 9433–9443.
- [20] Q. Ma, X. Tan, Y. Qu, L. Ma, Z. Zhang, Y. Xie, Cotr: Compact occupancy transformer for vision-based 3d occupancy prediction, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024, pp. 19936–19945. [doi:10.1109/CVPR52733.2024.01884](https://doi.org/10.1109/CVPR52733.2024.01884).

- [21] Y. Wang, Y. Chen, X. Liao, L. Fan, Z. Zhang, Panoocc: Unified occupancy representation for camera-based 3d panoptic segmentation, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024, pp. 17158–17168.
- [22] H. Liu, Y. Chen, H. Wang, Z. Yang, T. Li, J. Zeng, L. Chen, H. Li, L. Wang, Fully sparse 3d occupancy prediction, in: Proceedings of the European Conference on Computer Vision, 2024.
- [23] P. Tang, Z. Wang, G. Wang, J. Zheng, X. Ren, B. Feng, C. Ma, Sparseocc: Rethinking sparse latent representation for vision-based semantic occupancy prediction, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024.
- [24] Z. Yu, C. Shu, J. Deng, K. Lu, Z. Liu, J. Yu, D. Yang, H. Li, Y. Chen, Flashocc: Fast and memory-efficient occupancy prediction via channel-to-height plugin, arXiv preprint arXiv:2311.12058 (2023).
- [25] M. Pan, J. Liu, R. Zhang, P. Huang, X. Li, B. Wang, H. Xie, L. Liu, S. Zhang, Renderocc: Vision-centric 3d occupancy prediction with 2d rendering supervision, in: 2024 IEEE International Conference on Robotics and Automation, 2024, pp. 12404–12411.
- [26] J. Huang, G. Huang, Bevdet4d: Exploit temporal cues in multi-camera 3d object detection, arXiv preprint arXiv:2203.17054 (2022).
- [27] R. Mohan, J. V. Hurtado, R. Mohan, A. Valada, Forecastocc: Vision-based semantic occupancy forecasting, arXiv preprint arXiv:2602.08006 (2026).
- [28] X. Zhu, W. Su, L. Lu, B. Li, X. Wang, J. Dai, Deformable detr: Deformable transformers for end-to-end object detection, in: International Conference on Learning Representations, 2021.

- [29] A. Geiger, P. Lenz, R. Urtasun, Are we ready for autonomous driving? the kitti vision benchmark suite, in: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2012, pp. 3354–3361.
- [30] J. Behley, M. Garbade, A. Milioto, J. Quenzel, S. Behnke, C. Stachniss, J. Gall, Semantickitti: A dataset for semantic scene understanding of lidar sequences, in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019, pp. 9296–9306.
- [31] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, O. Beijbom, nuscenes: A multimodal dataset for autonomous driving, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020, pp. 11621–11631.
- [32] P. Jiang, P. Osteen, M. Wigness, S. Saripalli, Rellis-3d dataset: Data, benchmarks and analysis (2020). [arXiv:2011.12954](#).
- [33] A. Dosovitskiy, G. Ros, F. Codevilla, A. M. Lopez, V. Koltun, Carla: An open urban driving simulator, in: Proceedings of the 1st Conference on Robot Learning, 2017, pp. 1–16.
- [34] J. Tobin, R. Fong, A. Ray, J. Schneider, W. Zaremba, P. Abbeel, Domain randomization for transferring deep neural networks from simulation to the real world, in: 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems, 2017, pp. 23–30. [doi:10.1109/IRoS.2017.8202133](#).
- [35] X. B. Peng, M. Andrychowicz, W. Zaremba, P. Abbeel, Sim-to-real transfer of robotic control with dynamics randomization, in: 2018 IEEE International Conference on Robotics and Automation, 2018, pp. 3803–3810. [doi:10.1109/ICRA.2018.8460528](#).

- [36] J. Hoffman, E. Tzeng, T. Park, J.-Y. Zhu, P. Isola, K. Saenko, A. Efros, T. Darrell, Cycada: Cycle-consistent adversarial domain adaptation, in: Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1989–1998.
- [37] M. Chen, J. Mei, H. Zhai, S. Wang, T. Sun, F. Kong, H. Li, F. Mao, F. Liu, S. Wang, Y. Nie, Q. Zhu, L. Xiao, D. Zhao, Y. Hu, Advancing off-road autonomous driving: The large-scale orad-3d dataset and comprehensive benchmarks, arXiv preprint arXiv:2510.16500 (2025).